党政机关政策问答智能工作台

软件详细设计方案

1 场景与流程

工作台面向机关内部工作人员。工作人员接到企业或群众咨询后，像日常聊天一样输入问题，系统根据政策资料直接回答，并在相关语句后标注引用。点击引用可以查看原文，工作人员也可以继续追问。

系统结合对话识别事项、地区和办理时间。缺少影响结论的信息时，直接在对话中追问。用户也可以输入文件名称、文号或条款号，查询指定文件。

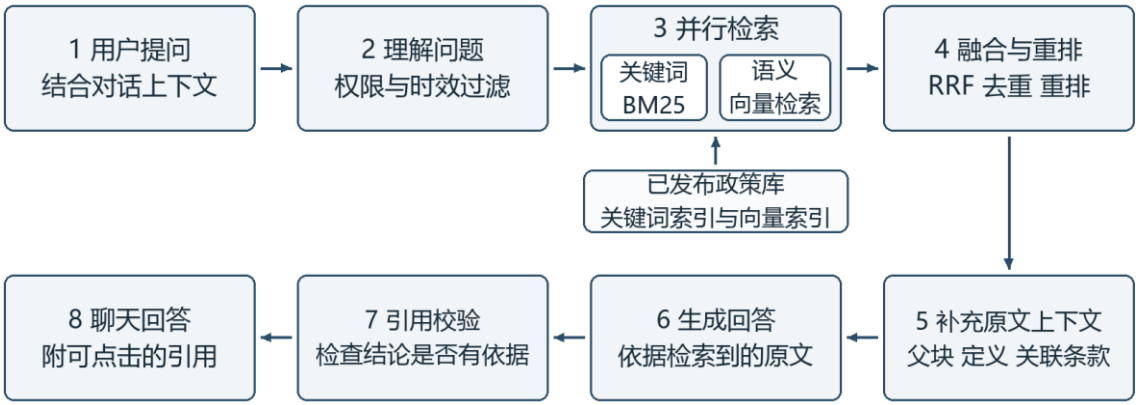


图 1 政策问答与 RAG 检索流程

一次对话的例子

工作人员问“企业今年还能否申请某项补贴”。系统确认地区和申报事项后，查找相关政策并回答，附上对应条款的引用。工作人员接着问“需要哪些材料”，系统沿用前面的信息，继续查询办事指南。没有找到当年申报通知时，就说明目前无法确认受理时间。

RAG 是“先检索资料，再依据资料回答”。图中两路检索同时查找政策条款，融合重排后补齐上下文，再交给模型回答。引用通过校验后展示；未找到依据时直接说明，用户可以继续追问。

2 政策文件入库

知识管理员按部门或主题批量导入政策文件。系统检查文件格式、可读性和重复内容，完成解析后，管理员对照原件校正，再审核发布。后台记录处理进度和失败原因，失败文件可以单独重试。

不同文件如何处理

类型	处理方法
Word 和文本 PDF	读取原生文字，保留标题层级、条款编号、段落顺序和表格。
扫描 PDF 和图片	通过 OCR 识别文字及版面，保存页码、文字坐标和原图。[1]
表格	保留表头、单位、行列关系及备注；跨页表格关联为同一张表。
图示和流程图	保留原图，必要时用视觉模型提取步骤和说明，结果回到原图核对。

金额、比例、日期和“不予”“除外”等词需要重点检查。识别质量不足的内容进入人工校正，确认前不用于生成确定结论。首期处理上述常见政策资料，音视频资料暂不展开。

入库时需要维护的信息

每份文件记录名称、文号、发布机关、来源、地区、适用对象、发布日期、生效日期、失效状态和维护责任人。政策原文、官方解读、办事指南及内部口径分别标识，在回答中说明来源类型。

文件所属部门与可见范围分别设置。工作人员可以在授权范围内跨部门查询，不能因为文件来自其他部门就直接排除，也不能因问题相关而绕过权限。

更新与历史版本

修订文件创建新版本，保留原件及替代、废止、配套等关系；部分条款调整时记录影响范围。新版本审核发布后参与当前查询，询问过去时点的问题时使用相应旧版本。有效状态不明确的文件先交维护部门确认。

查询时间同时作用于版本筛选和条款判断。发布日期、生效日期、申报期不能混用，涉及过渡安排时还要核对原文。文件撤回后立即停止访问，并同步清理索引和缓存。

3 切块与索引

结构与长度结合切分

本方案将条款切分与递归切分结合：先保留政策结构，再控制块的长度。标题、段落和句子提供拆分边界，chunk_size 是块长上限，chunk_overlap 是相邻块的重叠目标。[7][8]

方案	优点	需要补足的地方
只按条款切分	条号明确，引用和上下文关系清楚。	长条款仍需拆分；无条号文件需要其他规则。
标题 段落 句子加长度和重叠	适配普通文本，块长容易控制。	还需保留条款边界，避免混入不同规定或切断条件。

具体做法：按标题和条款分组；组内沿段落、句号等句界逐级拆分，再将相邻单元合并到长度上限内。短条款整体保留，超长句最后才按 token 拆开。中文分隔符显式配置，表格另按表头和相关行处理。

初始测试设 chunk_size 为 400 tokens，chunk_overlap 约 40 tokens，统一按向量模型的分词器计量。重叠只用于同一长条款内部的拆分，尽量保留完整句子，不跨文件、版本或不同条款。这些是测试起点，不代表最优值。

采用父子索引

子块是用于检索的较小片段，父块保存完整条款。问题命中某一款后，系统读取完整条款，补齐前置条件、例外和相关定义。回答引用仍定位到支持结论的具体款项。

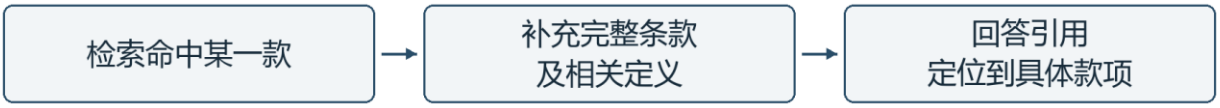


图 2 父子索引的使用方式

索引中保存什么

每个片段保存文档编号、版本编号、父块编号、条款路径、原文位置及访问范围。同一内容建立关键词索引和向量索引，分别支持准确词语匹配和语义查询。检索结果通过这些编号返回原文。

重叠片段和父块扩展都可能带来重复，生成前按原文位置去重，并控制上下文总量。PDF 保存页码和坐标，Word 保存条款、段落及版本预览位置；重叠不能改变引用所指向的原文。

4 检索流程

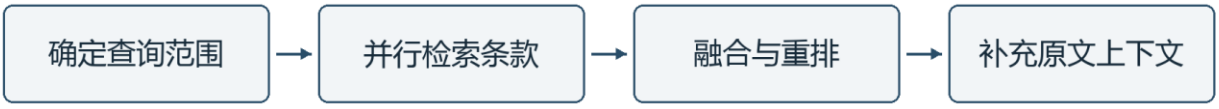


图 3 从问题到政策依据

先确定查询条件

系统识别事项、地区、办理时间、对象和文件信息。缺少影响结论的条件时先追问；用户指定历史时间时查相应版本。部门和主题用于优先检索，跨部门问题保留联合查询，避免只查一个部门而漏掉配套政策。

问题改写可以补充简称、常用说法和政策术语，但保留原问题及否定、时间等限制。不能把“哪些情况不能申请”改写成一般申请条件查询。

同时使用关键词和语义检索

检索方式	主要用途
精确查询	按文号、标题和条款号定位用户指定的文件。
关键词检索	用 BM25 匹配事项、部门、材料名称和专业术语，配合中文分词与同义词。
向量检索	把口语问题与政策中的正式表述关联起来，补充关键词未命中的条款。

融合 重排与补查

关键词和向量检索并行返回候选，采用 RRF 按各路排名融合、去重，再由重排模型筛选相关条款。[2] 明确指定文号的结果保留直接定位，不能在融合时丢失。

选出的子块补充父块和相关定义。条款明确引用实施细则、配套指南时，沿文件关系补查原文。涉及多个问题时分别检查证据，例如申请条件、材料要求和受理部门不能只找到其中一项就结束。

召回数量、重排数量和上下文长度通过问题集调整。相关性分数只用于排序，不能显示成“答案正确率”。所有检索、父块扩展和关联补查都执行相同的权限检查。

5 回答与引用

自然语言回答

模型接收问题、对话上下文和检索到的原文，直接回答用户。回答采用普通对话形式，长度随问题需要调整，相关政策结论后附引用。用户追问时结合前文重新检索，不能把上一轮模型回答直接当作政策依据。

金额、比例、日期和例外情形保留原意。缺少必要信息时在对话中询问。涉及不同政策时讲清各自适用条件，避免把它们拼成一个结论。

引用对应到具体结论

关键结论后标注可点击的引用，例如“[1]”。引用关联文件名称和条款号，点击后查看对应原文。后台保存文件版本和原文位置；表格引用同时保留相关行、表头和备注，便于查证。

模型只能选择系统提供的证据编号，文件链接和位置由系统生成。生成后检查引用是否存在，以及原文是否确实支持这项结论。只找到同主题文件，不足以为具体结论提供依据。

检查内容	重点
引用位置	文件、版本和条款存在，打开后能找到对应原文。
结论与原文	原文支持结论，金额、日期、对象和否定条件没有误读。
条件完整性	前置条件、例外及配套要求没有遗漏，多项问题均有回应。

无法确定时如何回答

没有找到依据时直接说明；条件不足时追问；文件说法有冲突时说明差异并附各自引用。系统不能仅因文件较新，就自动认定其替代了另一份文件。

引用与关键字段由程序校验，语义支持由模型辅助检查，并通过业务抽检验证。每次回答记录所用文件版本。政策更新后，新的问题按当前适用文件重新检索。

6 技术选型与增强检索

首期采用以下组合，优先验证中文政策检索和原文引用。组件版本在部署时固定，模型通过同一批政策问题比较后确定。

环节	建议组件	用途
文档解析	原生解析器与 PaddleOCR	读取电子文件，识别扫描件和表格。[1]
检索	OpenSearch	保存关键词、向量和筛选字段，执行混合检索。[2]
向量与重排	BGE-M3 与 bge-reranker-v2-m3	分别用于语义召回和候选条款排序。[3][4]
回答模型	Qwen3-14B 或 32B	作为私有化候选，比较证据遵循、引用准确性和速度。[5]
数据存储	PostgreSQL 与文件存储	保存版本、权限、文件关系、原件和预览。

模型服务可使用 vLLM 等推理服务。[5] 文件解析采用后台任务，问答与批量入库分配独立资源。实际硬件根据模型、上下文长度和并发测试确定，不只按模型参数量估算。

Agentic RAG 按需启用

常规问题走固定检索流程。复杂问题中，如果某个子问题缺少依据，或主政策指向其他文件，再让系统决定下一步补查什么。补查仅使用授权检索和文档读取工具，设置次数与时间上限；仍缺少依据时直接列出缺口。

这部分用于跨部门、多文件问题，不必让每次普通查询都经过反复规划。运行记录保留查询范围、补查文件和引用，方便排查。

GraphRAG 暂不作为主流程

首期先维护修订、废止、解释和配套关系，用于关联补查。完整 GraphRAG 还需要抽取和维护实体关系，其局部查询结合图关系与原文，全局查询更侧重全库概括。[6] 是否引入，取决于它能否改善跨文件漏检，以及维护成本是否可接受。

7 权限部署与验证

权限和部署

系统部署在单位批准的环境中，对接现有身份体系。文件按组织和可见范围授权，检索、引用预览、原件下载及历史回答查看都在服务端检查权限。缓存区分用户或权限集合、查询条件和知识版本，权限变化后及时失效。

原件、版本信息和配置定期备份，索引可由校正后的内容重建。模型不可用时返回已找到的原文；检索不可用时提示重试。文件中的指令性文字只作为资料，不能改变系统规则或工具权限。

重点验证什么

由业务部门提供真实、脱敏的问题，标注正确文件、条款和适用条件。先验证下列情况，再测试并发和响应时间。

情况	检查结果
普通及跨部门查询	应命中的条款能否找到，多文件问题是否遗漏依据。
历史版本与扫描表格	版本是否适用，金额日期及引用位置是否准确。
缺少条件或政策冲突	能否追问、说明缺口，避免生成无依据结论。
权限与政策更新	能否阻止越权访问，撤回和更新后结果是否同步变化。

验收记录条款召回、引用支持性、条件遗漏和无依据回答。切块对照测试使用同一批问题、相同召回数量和上下文预算，比较条款切分、递归切分及混合方案的召回、遗漏与重复量，再确定块长和重叠参数。演示按“政策入库、提问、查看引用、更新版本、再次查询”完成。

技术资料

[1] PaddleOCR 文档解析

[2] OpenSearch RRF 混合检索

[3] BGE-M3 向量模型

[4] BGE Reranker v2 重排模型

[5] Qwen3 模型与部署

[6] Microsoft GraphRAG 查询方式

[7] LangChain 递归切分与重叠参数

[8] Unstructured 文档结构与重叠切块